

Formulario 8: Diseño Factorial 2^k

Diseño de experimentos

Andrés Felipe Pico Zúñiga

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.colors as mcolors
import seaborn as sns
import statsmodels
import statsmodels.api as sm
from statsmodels.formula.api import ols
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import statsmodels.formula.api as smf
import scipy.stats as stats
```

Enunciado

En una planta donde se fabrican semiconductores se quiere mejorar el rendimiento del proceso vía diseño de experimentos. De acuerdo con la experiencia del grupo de mejora, los factores que podrían tener mayor influencia sobre la variable de respuesta (rendimiento), así como los niveles de prueba utilizados son los siguientes:

- A = Nivel de la abertura (pequeña, grande) = (-1,1).
- B = Tiempo de exposición (20% abajo, 20% arriba) = (-1,1).
- C = Tiempo de revelado (30 seg, 45 seg) = (-1,1).
- D = Dimensión de la máscara (pequeña, grande) = (-1,1).
- E = Tiempo de grabado (14.5 min, 15.5 min) = (-1,1).

Se decide correr un experimento 25 con una sola corrida o réplica para estudiar estos cinco factores. Se hacen las 32 corridas a nivel proceso.

Creación y visualización del dataframe

```
A = Nivel_abertura = [ "-1" , "1" ]
B = Tiempo_exposición = [ "-1" , "1" ]
C = Tiempo_revelado = [ "-1" , "1" ]
D = Dimensión_máscara = [ "-1" , "1" ]
E = Tiempo_grabado = [ "-1" , "1" ]
rendimiento = [7, 9, 34, 55, 16, 20, 40, 60,
               8, 10, 32, 50, 18, 21, 44, 61,
               18, 12, 35, 52, 15, 22, 45, 65,
               6, 10, 30, 53, 15, 20, 41, 63]
```

```

Nivel_abertura = (["-1"] * 1 + ["1"] * 1)*16

Tiempo_exposición = (["-1"] * 2 + ["1"] * 2 ) * 8
Tiempo_revelado = (["-1"] * 4 + ["1"] * 4)*4

Dimensión_máscara = (["-1"] * 8 + ["1"] * 8 ) * 2
Tiempo_grabado = ["-1"] * 16 + ["1"] * 16

df = pd.DataFrame({
    'A': Nivel_abertura,
    'B': Tiempo_exposición,
    'C': Tiempo_revelado,
    'D': Dimensión_máscara,
    'E': Tiempo_grabado,
    'rendimiento': rendimiento
})

print(df)

```

```

##      A    B    C    D    E  rendimiento
## 0   -1   -1   -1   -1   -1           7
## 1    1   -1   -1   -1   -1           9
## 2   -1    1   -1   -1   -1          34
## 3    1    1   -1   -1   -1          55
## 4   -1   -1    1   -1   -1          16
## 5    1   -1    1   -1   -1          20
## 6   -1    1    1   -1   -1          40
## 7    1    1    1   -1   -1          60
## 8   -1   -1   -1    1   -1           8
## 9    1   -1   -1    1   -1          10
## 10   -1    1   -1    1   -1          32
## 11    1    1   -1    1   -1          50
## 12   -1   -1    1    1   -1          18
## 13    1   -1    1    1   -1          21
## 14   -1    1    1    1   -1          44
## 15    1    1    1    1   -1          61
## 16   -1   -1   -1   -1    1          18
## 17    1   -1   -1   -1    1          12
## 18   -1    1   -1   -1    1          35
## 19    1    1   -1   -1    1          52
## 20   -1   -1    1   -1    1          15
## 21    1   -1    1   -1    1          22
## 22   -1    1    1   -1    1          45
## 23    1    1    1   -1    1          65
## 24   -1   -1   -1    1    1           6
## 25    1   -1   -1    1    1          10
## 26   -1    1   -1    1    1          30
## 27    1    1   -1    1    1          53
## 28   -1   -1    1    1    1          15
## 29    1   -1    1    1    1          20
## 30   -1    1    1    1    1          41
## 31    1    1    1    1    1          63

```

Tabla ANOVA

Efectos principales e interacciones dobles

```
modelo1 = ols(
    "rendimiento ~ (A+B+C+D+E)**2",
    data=df
).fit()
anova_result = sm.stats.anova_lm(modelo1, typ=1)
print (anova_result)
```

##	df	sum_sq	mean_sq	F	PR(>F)
## A	1.0	1001.28125	1001.281250	156.679707	1.113803e-09
## B	1.0	8877.78125	8877.781250	1389.188264	5.576883e-17
## C	1.0	657.03125	657.031250	102.811736	2.264156e-08
## D	1.0	16.53125	16.531250	2.586797	1.273092e-01
## E	1.0	9.03125	9.031250	1.413203	2.518705e-01
## A:B	1.0	586.53125	586.531250	91.779951	4.971986e-08
## A:C	1.0	9.03125	9.031250	1.413203	2.518705e-01
## A:D	1.0	2.53125	2.531250	0.396088	5.379999e-01
## A:E	1.0	0.78125	0.781250	0.122249	7.311672e-01
## B:C	1.0	3.78125	3.781250	0.591687	4.529740e-01
## B:D	1.0	0.03125	0.031250	0.004890	9.451172e-01
## B:E	1.0	0.03125	0.031250	0.004890	9.451172e-01
## C:D	1.0	16.53125	16.531250	2.586797	1.273092e-01
## C:E	1.0	0.78125	0.781250	0.122249	7.311672e-01
## D:E	1.0	26.28125	26.281250	4.112469	5.955770e-02
## Residual	16.0	102.25000	6.390625	NaN	NaN

```
modelo2 = sm.OLS.from_formula(
    'rendimiento ~ (A+B+C+D+E)**2',
    data=df
).fit()
print(modelo2.summary())
```

OLS Regression Results						
##	=====					
## Dep. Variable:	rendimiento	R-squared:	0.991			
## Model:	OLS	Adj. R-squared:	0.982			
## Method:	Least Squares	F-statistic:	116.9			
## Date:	vie, 17 oct 2025	Prob (F-statistic):	1.88e-13			
## Time:	12:55:36	Log-Likelihood:	-63.993			
## No. Observations:	32	AIC:	160.0			
## Df Residuals:	16	BIC:	183.4			
## Df Model:	15					
## Covariance Type:	nonrobust					
##	coef	std err	t	P> t	[0.025	0.975]
##	-----					
## Intercept	9.4375	1.788	5.280	0.000	5.648	13.227
## A[T.1]	0.6875	1.999	0.344	0.735	-3.549	4.924
## B[T.1]	24.1875	1.999	12.103	0.000	19.951	28.424
## C[T.1]	6.1875	1.999	3.096	0.007	1.951	10.424
## D[T.1]	-1.5625	1.999	-0.782	0.446	-5.799	2.674
## E[T.1]	2.9375	1.999	1.470	0.161	-1.299	7.174

```
## A[T.1]:B[T.1]    17.1250    1.788    9.580    0.000    13.336    20.914
## A[T.1]:C[T.1]    2.1250    1.788    1.189    0.252    -1.664    5.914
## A[T.1]:D[T.1]    1.1250    1.788    0.629    0.538    -2.664    4.914
## A[T.1]:E[T.1]    0.6250    1.788    0.350    0.731    -3.164    4.414
## B[T.1]:C[T.1]    1.3750    1.788    0.769    0.453    -2.414    5.164
## B[T.1]:D[T.1]   -0.1250    1.788   -0.070    0.945    -3.914    3.664
## B[T.1]:E[T.1]   -0.1250    1.788   -0.070    0.945    -3.914    3.664
## C[T.1]:D[T.1]    2.8750    1.788    1.608    0.127    -0.914    6.664
## C[T.1]:E[T.1]   -0.6250    1.788   -0.350    0.731    -4.414    3.164
## D[T.1]:E[T.1]   -3.6250    1.788   -2.028    0.060    -7.414    0.164
## =====
## Omnibus:                8.034   Durbin-Watson:                2.194
## Prob(Omnibus):          0.018   Jarque-Bera (JB):          6.651
## Skew:                   0.856   Prob(JB):                  0.0360
## Kurtosis:               4.434   Cond. No.                  14.7
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Optimización

```
from scipy.optimize import minimize

# Define la función que deseas maximizar se antepone el signo (-)
def funcion(x):
    return -(9.437 + 0.687*x[0] + 24.187*x[1] + 6.187*x[2] - 1.563*x[3] + 2.937*x[4] + 17.125*x[0]*x[1])

# Define las restricciones para x
def variables(x):
    return x[0], x[1], x[2], x[3], x[4]

# Definir las restricciones de límite para x
restricciones = [(-1, 1), (-1, 1), (-1, 1), (-1, 1), (-1, 1)]

# Suprimir la salida de la optimización
res = minimize(funcion, [0, 0, 0, 0, 0], method='SLSQP', constraints={'type':'ineq', 'fun': variables},

# Imprimir el resultado
print("Resultado óptimo:")

## Resultado óptimo:
print("x:", res.x)

## x: [9.99999998e-01 9.99999997e-01 9.99999998e-01 1.27861136e-11
##      9.99999998e-01]

print("Valor Máximo:", -res.fun) # Como minimizamos el negativo de la función

## Valor Máximo: 63.93499981295733
```

Colapsando el Factor E

```

modelo3 = ols(
    "rendimiento ~ (A+B+C+D)**2",
    data=df
).fit()
anova_result = sm.stats.anova_lm(modelo3, typ=1)
print (anova_result)

```

##	df	sum_sq	mean_sq	F	PR(>F)
## A	1.0	1001.28125	1001.281250	151.102852	4.665074e-11
## B	1.0	8877.78125	8877.781250	1339.741523	1.649690e-20
## C	1.0	657.03125	657.031250	99.152257	2.087253e-09
## D	1.0	16.53125	16.531250	2.494723	1.291741e-01
## A:B	1.0	586.53125	586.531250	88.513137	5.577236e-09
## A:C	1.0	9.03125	9.031250	1.362901	2.561204e-01
## A:D	1.0	2.53125	2.531250	0.381990	5.431858e-01
## B:C	1.0	3.78125	3.781250	0.570627	4.583996e-01
## B:D	1.0	0.03125	0.031250	0.004716	9.458999e-01
## C:D	1.0	16.53125	16.531250	2.494723	1.291741e-01
## Residual	21.0	139.15625	6.626488	NaN	NaN

Optimización

```
modelo3.params
```

```

## Intercept      10.90625
## A[T.1]          1.00000
## B[T.1]          24.12500
## C[T.1]           5.87500
## D[T.1]         -3.37500
## A[T.1]:B[T.1]   17.12500
## A[T.1]:C[T.1]    2.12500
## A[T.1]:D[T.1]    1.12500
## B[T.1]:C[T.1]    1.37500
## B[T.1]:D[T.1]   -0.12500
## C[T.1]:D[T.1]    2.87500
## dtype: float64

```

Colapsando el Factor D

```

modelo4 = ols(
    "rendimiento ~ (A+B+C)**2",
    data=df
).fit()
anova_result = sm.stats.anova_lm(modelo4, typ=1)
print (anova_result)

```

##	df	sum_sq	mean_sq	F	PR(>F)
## A	1.0	1001.28125	1001.28125	143.219203	7.613839e-12
## B	1.0	8877.78125	8877.78125	1269.841766	5.944113e-23
## C	1.0	657.03125	657.03125	93.979081	5.977636e-10
## A:B	1.0	586.53125	586.53125	83.895047	1.829092e-09
## A:C	1.0	9.03125	9.03125	1.291793	2.664954e-01
## B:C	1.0	3.78125	3.78125	0.540855	4.689226e-01
## Residual	25.0	174.78125	6.99125	NaN	NaN

Optimización

modelo4.params

```
## Intercept          9.21875
## A[T.1]             1.56250
## B[T.1]             24.06250
## C[T.1]             7.31250
## A[T.1]:B[T.1]      17.12500
## A[T.1]:C[T.1]      2.12500
## B[T.1]:C[T.1]      1.37500
## dtype: float64
```